

МІНІСТЕРСТВО ОСВІТИ І НАУКИ УКРАЇНИ
ЛЬВІВСЬКИЙ НАЦІОНАЛЬНИЙ УНІВЕРСИТЕТ ІМЕНІ ІВАНА ФРАНКА

Факультет електроніки та комп'ютерних технологій

ЗВІТ

З ЛАБОРАТОРНОЇ РОБОТИ №1

з дисципліни «Інженерія даних»

на тему: «Ініціалізація проєкту та первинне дослідження джерел даних»

Виконав:
Студент 3 курсу
групи ФЕП-34
Полянський Тимотей

Перевірів:
ас. Фостяк Маркіян Романович

1. Мета роботи та конфігурація середовища

Мета роботи: налаштувати ізольоване робоче середовище Python та Git-репозиторій індивідуального проєкту. Опанувати зчитування CSV-файлів за допомогою pandas, дослідити їхню структуру, визначити рівень зернистості (grain), кандидатні ключі та зв'язки, виявити аномалії й проблеми якості сирих даних та задокументувати отримані результати без модифікації первинних файлів[cite: 17, 20].

Конфігурація робочої станції та проєкту:

- **Вхідний пакет даних:** CityFlow S08 (cityflow_s08_base_v1.zip), цілісність верифіковано утилітою sha256sum[cite: 10, 17, 20].
- **ОС та термінальне середовище:** Omarchy (Arch Linux, Wayland), оболонка fish, редактор Neovim, мультиплексор tmux.
- **Стек обробки даних:** Python 3.14.7, менеджер пакетів та віртуальних оточень uv (без pip/conda), бібліотеки pandas, matplotlib, jupyter[cite: 20].
- **Контроль версій:** git, консольний UI lazygit, gh (GitHub CLI). Роботу виконано в гілці lab/01-init-profiling[cite: 10, 17, 20].
- **Посилання на репозиторій:** GitHub / uni_data_engineering | **Pull Request:** PR #1 (Merged) | **Тег релізу:** lab-01-v1[cite: 17, 20].

2. Опис джерел даних та рівень деталізації (Grain)

У рамках навчального сервісу доставки CityFlow досліджено чотири базові таблиці[cite: 17, 20]:

Файл	Кандидатний ключ	Зернистість (Grain)	Зв'язки (Foreign Keys)
customers.csv	customer_id	Один зареєстрований користувач	Батьківська таблиця для orders.customer_id
merchants.csv	merchant_id	Один заклад-партнер сервісу	Батьківська таблиця для товарів і замовлень
products.csv	product_id	Один товар конкретного закладу	merchant_id -> merchants.merchant_id
orders.csv	order_id	Одне сформоване замовлення	customer_id -> customers, merchant_id -> merchants

3. Підсумкова діагностична таблиця датасетів

Усі метрики розраховано в notebooks/01_source_profiling.ipynb за допомогою pandas. Джерельні CSV розміщено в data/raw/ у незмінному вигляді[cite: 17, 20].

Датасет	Рядків	Колонки	Дублювати	Пропуски	Унікальні РК	Часовий діапазон записів
customers	1 000	6	1	5	999	2024-03-10 — 2026-08-29
merchants	35	5	1	0	34	2019-09-07 — 2025-07-19
products	500	5	1	0	499	N/A (часове поле відсутнє)
orders	6 000	7	1	0	5 999	2025-09-01 — 2026-08-31

Примітка: датасет orders додатково містить 2 пошкоджені часові мітки, що не піддаються парсингу у валідні дати (результат: NaT).

4. Візуальний аналіз розподілів

Для первинного аналізу динаміки та статусів транзакцій побудовано два діагностичні графіки (збережені в docs/ як статичні PNG без використання графічного інтерфейсу)[cite: 17, 20]:




Рисунок 1: Розподіл замовлень сервісу CityFlow за статусами (пакет S08)

Аналіз статусів замовлень: Домінуюча частка транзакцій має фінальний успішний статус delivered (4 966 записів). Частка скасованих замовлень cancelled становить 449 записів. Повернення коштів клієнтам представлені категоріями partially_refunded (223) та refunded (198). Кількість збійних замовлень (failed) дорівнює 162. Активних замовлень у процесі виконання (in_progress) зафіксовано лише 3, що підтверджує переважно історичний характер транзакційного масиву.




Рисунок 2: Часова динаміка замовлень за період вересень 2025 — серпень 2026

Аналіз динаміки замовлень: Транзакції розподілені стабільно протягом річного вікна спостереження із середньодобовим навантаженням близько 15–25 замовлень на добу. Критичних часових розривів даних, аномальних падінь чи штучних сплесків активності протягом досліджуваного періоду не зафіксовано.

5. Реєстр виявлених проблем якості даних

За результатами перевірок у docs/data_quality_findings.md зафіксовано 6 категорій аномалій[cite: 17, 20]:

Файл	Поле / Дефект	К-сть	Приклад ID	Потенційний ризик / Вплив	Запропоноване рішення
Всі 4 CSV	Повні дубліка-ти рядків	4	S08-C000504 S08-00000683	Завищення сумарної виручки, падіння обмеження PK (UNIQUE) у базі	Дедуплікація під час перенесення в Staging (DROP DUPLICATES)
customers	phone (значення NULL)	5	S08-C000301	Неможливість SMS-інформування або дзвінка кур'єра клієнту	Допустити NULL, виставити технічний прапорець unverified_phone
products	unit_price_uah <= 0	1	S08-P000331	Збій розрахунку чеків, порушення констрейнту CHECK (price > 0)	Уточнення бізнес-правила або ізоляція запису в карантин
products	Сирітний FK закладу	1	S08-P000331	Порушення посилальної цілісності FOREIGN KEY у PostgreSQL	Маршрутизація в карантин (DLQ) або підстановка сурогату UNKNOWN
orders	Сирітний FK клієнта/мерчанта	2	S08-00004825 S08-00005136	Втрата транзакцій при виконанні INNER JOIN у звітності	Ізоляція в буферну карантинну таблицю до з'ясування причин
orders	currency == "UAH"	1	S08-00003912	Фрагментація групувань GROUP BY currency у звітах та BI	Нормалізація рядка функцією REPLACE або регулярним виразом
orders	created_at (пошкоджені)	2	S08-00001204	Неможливість приведення до типу TIMESTAMPTZ у базі даних	Збереження сирого рядка в аудит-полі, NULL для аналітики

6. Архітектура конвеєра даних (Architecture v0)

Схема руху даних на етапі Лабораторної роботи №1 відображає поточні артефакти та ізоляцію сирих файлів[cite: 17, 20]:




Рисунок 3: Архітектурна схема поточного та запланованого конвеєра даних CityFlow

Опис архітектури:

- Вхідний шар:** архів cityflow_S08_base_v1.zip верифіковано та розпаковано у data/raw/ (виключено з Git)[cite: 17, 20].
- Шар профілювання:** модуль 01_source_profiling.py зчитує CSV, обчислює метрики та пише семпли у data/sample/[cite: 17, 20].
- Шар документації:** зафіксовано словник даних, реєстр проблем та архітектурну схему проєкту[cite: 17, 20].
- Заплановані модулі:** імпорт у PostgreSQL (Staging/Core), валідація та DWH позначені пунктиром і реалізуються далі[cite: 17, 18, 20].

7. Висновки та обмеження

1. **Зернистість:** для всіх 4 таблиць визначено однозначні бізнес-ключі (`customer_id`, `merchant_id`, `product_id`, `order_id`)[cite: 17, 20].
2. **Чистота джерел:** виявлено рівно по 1 повному дублікату в кожному CSV, що свідчить про системне дублювання при експорті.
3. **Референційна цілісність:** знайдено 3 сирітні записи без батьківських зв'язків. Пряме завантаження в Core-таблиці з FOREIGN KEY вимагає проміжного карантинного буфера (DLQ)[cite: 18, 20].
4. **Аномалії атрибутів:** виявлено ненормалізований код валюти (UA N), непозитивну ціну товару та 2 невалідні дати замовлень.
5. **Обмеження версії:** виконано виключно пасивний діагностичний аудит; сирі файли збережено незмінними, СУБД на цьому етапі не підключалася[cite: 17, 20].

8. Декларація використання ШІ (AI Usage)

Згідно з файлом `AI_USAGE.md` репозиторію[cite: 17, 20]:

- **Інструмент:** LLM-асистент (Gemini).
- **Завдання:** шаблонізація коду первинного профілювання даних (`pandas`, `jupyter`), структурування розмітки `data_dictionary.md`, генерація схеми `architecture_v0.png` через `matplotlib.patcher`, налагодження шаблону `Typst`[cite: 20].
- **Спосіб перевірки:** усі результати (кількості пропусків, типи даних, валідація FK, дублікати) підтверджено фактичним виконанням Python-скрипта на файлах пакета `cityflow_s08_base_v1.zip`[cite: 17, 20]. Роботу блокнота перевірено автоматичним перезапуском ядра через `nbconvert`[cite: 17, 20].

9. Відповіді на контрольні запитання

1. Що досліджує первинне профілювання і чим воно відрізняється від очищення?

Профілювання вимірює та фіксує поточний стан сирих джерел (типи, обсяги, пропуски, розподіли, цілісність) без модифікації файлів[cite: 17, 20]. Очищення — це активна мутація даних (фільтрація, приведення типів, імпутація, дедуплікація) на етапі ETL/Staging[cite: 17, 18, 20].

2. Що представляє рядок у кожному з ваших файлів? Як перевірити кандидатний ключ?

`customers`: зареєстрований користувач; `merchants`: заклад; `products`: товарна позиція; `orders`: транзакція замовлення[cite: 17, 20]. Перевірка ключа: `df[col].is_unique` або порівняння `df[col].nunique() == len(df)`[cite: 17, 20].

3. Чим повний дублікат відрізняється від повторення ключа з іншими значеннями?

Повний дублікат (`df.duplicated()`) означає абсолютний збіг усіх колонок рядка[cite: 17, 20]. Повторення ключа при відмінних інших атрибутах свідчить про конфлікт ідентифікатора або оновлення стану сутності без версіонування[cite: 23].

4. Чим відрізняються пропуск, порожній рядок, нуль і некоректна дата?

Пропуск (`NaN/NULL`) — відсутність значення в пам'яті[cite: 17, 20]. Порожній рядок (`""`) — валидний строковий об'єкт довжини 0[cite: 17, 20]. Нуль (`0`) — числове значення[cite: 17, 20]. Некоректна дата — пошкоджений рядок, який парсер перетворює на `NaT`[cite: 17, 20].

5. Як знайти замовлення, `customer_id` якого відсутній у файлі клієнтів?

У `pandas`: `orders[~orders['customer_id'].isin(customers['customer_id'])]`[cite: 17, 20]. В SQL: через `LEFT JOIN ... WHERE customers.customer_id IS NULL`[cite: 17, 20, 21].

6. Навіщо зберігати незмінні raw-файли та перевіряти контрольну суму?

Незмінність raw-даних забезпечує відтворюваність і можливість повторного аудиту[cite: 17, 18, 20]. Контрольна сума SHA-256 гарантує, що вхідний пакет не був модифікований чи пошкоджений при передачі[cite: 17, 20].

7. Що потрібно для запуску notebook на іншому комп'ютері? Що не слід додавати до Git?

Потрібні: маніфест залежностей (`pyproject.toml`, `uv.lock`) та версія Python[cite: 17, 20]. До Git заборонено додавати: важкі raw CSV, оточення `.venv/`, конфігурації з паролями (`.env`) та кеш `.ipynb_checkpoints`[cite: 17, 20].

8. Які висновки підтверджені вашими даними, а які є припущеннями? Як перевірено допомогу ШІ?

Факти: 1 повний дублікат у кожному CSV, 5 пропусків у `phone`, сирітні ID `S08-00004825`, `S08-00005136`, `S08-P000331`, значення `UA N`[cite: 17, 20]. **Припущення:** допустимість `phone = NULL`, трактування ціни `<= 0` як тестового товару. Допомогу ШІ верифіковано автономним виконанням розрахунків на локальній системі[cite: 17, 20].